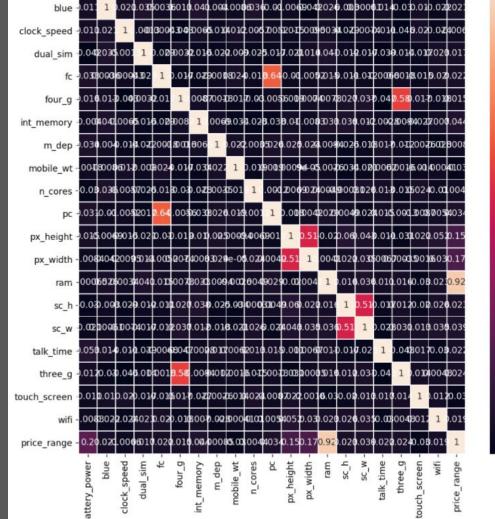
# Pràctica 2 Classificació

Aprenentatge Computacional

### Introdució al dataset

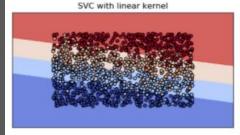
- Classificació per preu de mòbils
- 2000 mostres, 21 variables
- Distribucions binàries minoritàries
- El nostre atribut objectiu és el rang de preu del mòbil
- Dataset dividit en dos arxius: train.csv
  i test.csv
- Correlació lineal baixa per a qüasi totes les variables, moderada per al battery\_power, px\_height i px\_width i alta per a la ram

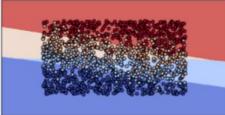


- 0.4

- 0.2

battery\_power





LinearSVC (linear kernel)

SVC with RBF kernel



SVC with polynomial (degree 3) kernel



Acuracy of SVC with linear kernel: 0.8257142857142857

Acuracy of LinearSVC (linear kernel): 0.7607142857142857

Acuracy of SVC with RBF kernel: 0.8214285714285714

Acuracy of SVC with polynomial (degree 3) kernel: 0.7864285714285715

Acuracy of Random Forest: 1.0

Acuracy of Gaussian Naive Bayes: 0.7664285714285715

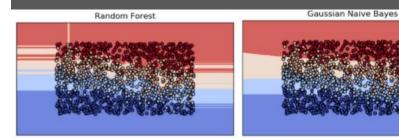
Acuracy of KNN: 0.8721428571428571

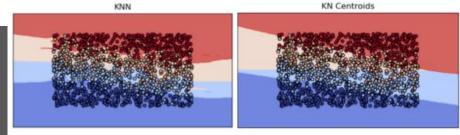
Acuracy of KN Centroids: 0.7907142857142857

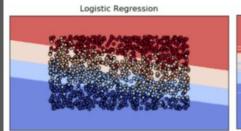
Acuracy of Logistic Regression: 0.8242857142857143

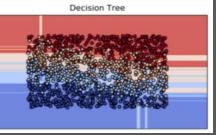
Acuracy of Decision Tree : 1.0

#### Anàlisi de les classificacions









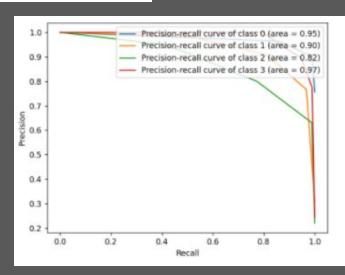
#### Crossvalidation

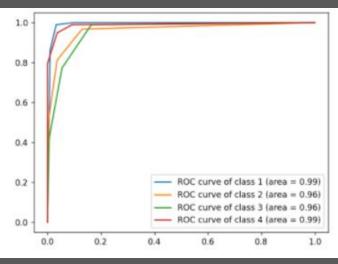
- 2: 0.785625
- 3 : 0.7862428062482872
- 4: 0.7943749999999999
- 5: 0.791875
- 6: 0.7912125820168399
- 7: 0.7868388219456939
- 8: 0.78875000000000001
- 9: 0.7843444282217849
- 10: 0.784999999999999
- 11: 0.7868037961094174
- 12 : 0.7849427673661767
- 13: 0.7862272791462406
- 13 . 0./6022/2/91402400
- 14: 0.7874359812574916
- 15: 0.7848939046611416
- 16: 0.78625
- 17: 0.7850009880772016
- 18: 0.7861976506639426
- 19: 0.7855521155830754
- 20: 0.7825

- Avaluació dels models
- Utilitzem KFold com a estratègia
- K = 4
- LeaveOneOut massa costós en temps

# Metric Analytics

	precision	recall	f1-score	support
0	0.91	1.00	0.95	93
1	0.92	0.86	0.89	122
2	0.85	0.82	0.83	88
3	0.93	0.95	0.94	97
accuracy			0.91	400
macro avg	0.90	0.91	0.90	400
weighted avg	0.90	0.91	0.90	400





## Hyperparameter Search

Randomized Parameter Optimitzation vs Exhaustive Grid Search

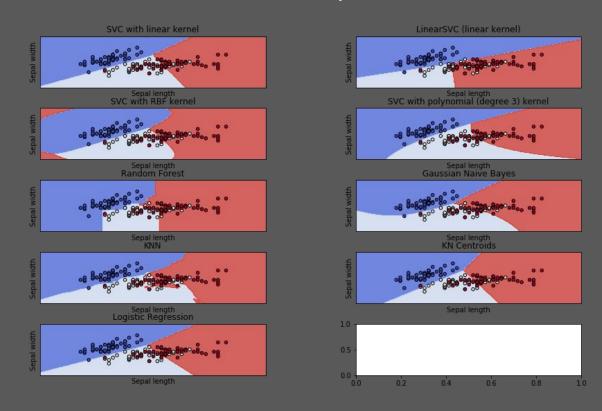
Després d'aquest procés, hem trobat que els millor valors eren els següents:

- Gaussian Naive Bayes: {'var\_smoothing': 0.43287612810830584}
- KNN: {'leaf\_size': 1, 'n\_neighbors': 38, 'p': 1}
- Logistic Regression: {'C': 0.0001, 'penalty': 'none'}
- Decision Tree: {'criterion': 'entropy', 'max\_depth': 20, 'min\_samples\_leaf':

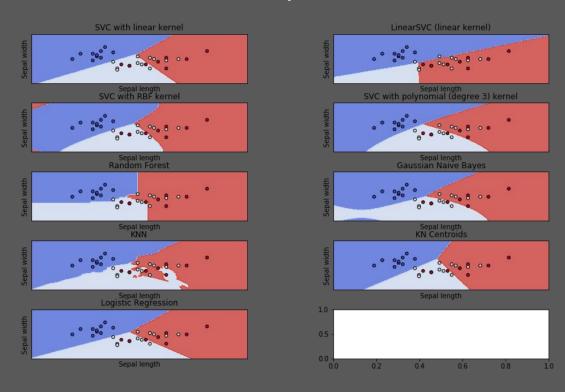
5}

# Apartat B

#### Classificació amb tot el conjunt de dades



#### Classificació amb el conjunt de dades d'entrenament



### Problemes + Conclusions

- No em vist gaire dificultat en el que se'ns demanava
- Trobar el millor valor per els hiperparàmetres
- Triar la millor mètrica de classificació